

채널 어텐션 기반 U-Net과 손실 함수 최적화를 통한 화이트밸런스 노이즈 제거

김주영, *김수민, *정영범

성신여자대학교, *성신여자대학교, *성신여자대학교

annajy1425@gmail.com, *20222631@sungshin.ac.kr, *ybjung@sungshin.ac.kr

Channel Attention-Based U-Net with Optimized Loss Functions for White Balance Noise Removal

Jooyoung Kim *Sumin Kim *Youngbeom Jeong

Sungshin Women's University *Sungshin Women's University *Sungshin Women's University

요 약

본 논문은 화이트밸런스 불균일성 노이즈로 손상된 이미지의 복원 성능을 향상시키기 위해 pix2pix 기반 구조를 최적화하였다. 기존 CBAM 모듈을 채널 어텐션(CAM)과 공간 어텐션(SAM)으로 분리해 분석한 결과, SAM은 성능을 저해하는 요소로 나타났으며, 이에 따라 CAM만을 U-Net 디코더 전 단계에 삽입한 구조를 제안하였다. 또한 L1 및 LPIPS 손실의 가중치를 조정한 결과, $\lambda_{L1}=100$, $\lambda_{LPIPS}=1.0$ 조합에서 최적의 성능을 보였다. 제안 모델은 기존 CBAM 기반 대비 LPIPS는 54.7% 감소했고, PSNR은 +5.53 dB 향상되었으며, SSIM은 23.2% 개선되어 화이트밸런스 왜곡 복원에 효과적임을 확인할 수 있었다.

1. 서론

이미지 노이즈 제거(Image Denoising)는 컴퓨터 비전 분야에서 꾸준히 연구되었으나 실제 환경에서 나타나는 복합적이고 불규칙한 노이즈를 완벽히 처리하는 일은 여전히 쉽지 않다. 특히 조명 조건이나 센서 반응 차이에서 비롯되는 화이트밸런스 불균일성은 색상 왜곡과 정보 손실을 동시에 일으키며, 기존 CNN 기반 복원 구조만으로는 이러한 비정형적인 왜곡을 제대로 다루기 어렵다.

이를 개선하기 위해 최근 연구에서는 이미지-투-이미지 변환에서 강력한 성능을 보이는 pix2pix 구조에 주의 메커니즘(CBAM)과 지각 손실(LPIPS)을 결합하는 방안이 시도되고 있다. 그러나 CBAM이 채널 어텐션(CAM)과 공간 어텐션(SAM)으로 이루어져 있음에도, 두 모듈의 개별적인 효과와 최적 삽입 위치는 충분하게 검증되지 않았다. 또한 L1 손실과 LPIPS 손실 가중치 조합에 대해서도 체계적인 분석은 부족한 상황이다.

이 연구는 채널 단위 특징 보정(CAM)이 화이트밸런스 왜곡 복원에 특히 효과적일 것이라는 가정에서 출발한다. 이를 토대로 네트워크 구조와 손실 함수의 최적화를 함께 탐구하여, 손실 함수의 조합을 최적화함으로써 픽셀 단위 정확성과 시각적

유사도를 동시에 높이는 방법을 모색했다. 구체적으로 본 연구에서의 내용은 다음과 같다.

첫째, CBAM을 CAM과 SAM으로 분리해 각각의 성능을 검증하고, CAM만을 U-Net 디코더 전 단계에 삽입하는 최적 구조를 제안한다. 둘째, 해당 구조를 기반으로 L1 손실과 LPIPS 손실의 다양한 가중치 조합을 실험하여 최적 학습 전략을 알아본다. 마지막으로, 제안 모델이 기존 CBAM 기반 모델 대비 복원 정확도와 시각적 유사도 모두에서 개선된 성능을 보이는 것을 확인한다.

2. 관련 연구

이미지 노이즈 제거에서 기존 방법들은 특정 노이즈 유형에 최적화된 경우가 많아 실제 환경에서 발생하는 복합적이고 불규칙한 화이트밸런스 왜곡에는 취약하다[5][6]. 최근에는 이미지-투-이미지(Image-to-Image) 변환 기반 딥러닝 기법이 복원 문제에 널리 활용되고 있으며, 그중 pix2pix 구조는 지역적인 디테일과 전역적 구조를 동시에 보존할 수 있다는 점에서 주목받고 있다[1].

2.1 pix2pix 조건부 GAN 구조

pix2pix는 조건부 생성적 적대 신경망(Conditional GAN)을 이용해 입력 이미지를 목표 이미지로 변환한다[1]. 이 과정에서 U-Net 기반 생성기(Generator)는 다중 해상도 특징을 효과적으로 통합하며[2], PatchGAN 판별기(Discriminator)는 부분 패치 단위에서 진위를 판별해 세부적인 디테일을 강화한다[1]. 이러한 특성 덕분에 pix2pix는 기존 CNN 기반 접근보다 우수한 복원 성능을 보이는 것으로 보고되었다[1].

2.2 LPIPS 시각 손실

LPIPS는 단순히 픽셀 간의 차이를 계산하는 대신 고차원 특징 공간에서의 유사도를 측정하여, 사람의 시각적 인지와 유사한 평가를 가능하게 한다[4]. 이는 기존 L1, L2 손실만 활용한 방법보다 더 자연스럽고 주관적으로 만족스러운 복원 결과를 이끌어낸다[4]. 다만 픽셀 단위 정밀도는 보장하지 못하기 때문에, 단독 적용보다는 L1 손실과 함께 적용했을 때 안정적인 성능을 보이는 것으로 알려져 있다[4].

2.3 CBAM 주의 메커니즘

CBAM은 채널 주의(CAM)와 공간 주의(SAM)를 통해 네트워크가 중요한 특징과 영역에 집중하도록 한다[3]. 이를 통해 복잡한 잡음을 억제하고 핵심 정보는 강조할 수 있다[3]. 하지만 기존 연구들은 CBAM 전체를 일괄적으로 적용하는 경우가 많았고, 각 모듈(CAM, SAM)의 개별 기여도와 최적 삽입 위치에 대한 체계적인 분석은 충분히 이루어지지 않았다[3].

2.4 화이트밸런스 보정 연구

화이트밸런스 왜곡은 조명 스펙트럼의 불균일성과 센서 반응 차이에서 비롯되어 색상 왜곡과 정보 손실을 일으킨다. 전통적으로는 Gray World 가정[7]이나 Retinex 이론[8]과 같은 통계적·물리 기반 접근이 활용되었으나, 다양한 조명 환경과 비정형 왜곡 상황에서는 한계가 뚜렷하다. 최근에는 딥러닝을 활용해 이미지 내 문맥 단서를 학습하여 색 균형을 보정하려는 연구가 이루어지고 있으나[9], 대부분 색 보정(color correction)에 집중되어 있어 노이즈 제거와 색상 복원을 동시에 고려하는 통합적 접근은 아직 부족하다.

3. 제안 기법

3.1 최적화된 네트워크 구조

본 연구는 pix2pix 구조[1]를 기반으로 하며, Generator로는 U-Net[2], Discriminator로는 PatchGAN[1]을 사용한다. 기존 CBAM 연구[3]에서는 모듈을 일괄 적용하는 데 그쳐 삽입 위치에 대한 구체적 검증이 부족했다. 본 연구에서는 CBAM을 CAM과 SAM으로 분리해 살펴보고, CAM의 최적 삽입 위치를 직접 실험을 통해 탐구했다. 그 결과, U-Net의 Decoder 전 구간에 CAM을 배치하는 구조가 가장 효과적인 것으로 나타났다.

3.1.1 채널 어텐션 모듈(CAM) 단독 사용

분해 실험 결과, SAM은 오히려 성능을 저해하는 요인으로 확인되었다. 따라서 CBAM 전체 대신 CAM만을 Generator에 적용했다. CAM은 전역 평균 풀링과 전역 최대 풀링 결과를 다중 퍼셉트론(MLP)에 통과시켜 각 채널별 중요도를 계산하고, 이를 기반으로 채널 가중치를 학습한다.


3.1.2 CAM의 Decoder All 삽입

CAM의 최적 삽입 위치를 검증하기 위해 Encoder 단계와 Decoder 단계에 각각 CAM을 삽입하는 실험을 진행했다. 그 결과, U-Net의 모든 디코더 단계(u1~u4) 출력 직후에 CAM을 삽입했을 때 가장 우수한 성능을 보였다. 이는 화이트밸런스 복원의 핵심이 스킵 커넥션을 통합하고 최종 이미지를 재구성하는 디코더 단계에 있음을 보여준다. 특히 이 단계에서 채널별 특징 보정이 가장 효과적으로 이루어졌다.

3.1.3 제안 구조 시각화

제안하는 전체 네트워크 구조는 그림 1에 나타났다. Generator는 U-net 기반으로 구성되며, 각 디코더 단계 출력 직후 CAM이 삽입되어 채널별 중요도를 보정한다. Discriminator는 PatchGAN을 사용하여 지역적 패치 단위에서 복원 이미지와 정답 이미지를 구분한다. 즉, 제안 모델은 디코더 단계의 채널 보정(CAM)과 패치 단위 판별(PatchGAN)을 결합해 화이트밸런스 왜곡 복원 성능을 강화한다.

그림 1. 제안 네트워크 구조: U-net 기반 Generator(Decoder 단계에 CAM 삽입) 와 PatchGAN Discriminator



3.2 복합 손실 함수 최적화

Generator의 최종 학습 손실은 다음과 같이 정의된다:

$$L_{total} = \lambda_{L1} \cdot L_{L1} + \lambda_{GAN} \cdot L_{GAN} + \lambda_{LPIPS} \cdot L_{LPIPS}$$

본 연구에서는 CAM-Decoder All 구조를 기반으로 L_{L1} 과 L_{LPIPS} 의 가중치를 체계적으로 분석했다. 실험 결과, $\lambda_{L1}=100$, $\lambda_{LPIPS}=1.0$ 일 때 가장 좋은 성능을 얻을 수 있었다. 이는 픽셀 단위 정확성을 확보하는 L_{L1} 과 시각적 유사도를 반영하는 L_{LPIPS} 사이의 균형이 화이트밸런스 왜곡 복원에서 핵심적임을 보여준다.

3.3 정규화 및 출력 처리

효과적인 학습을 위해 입력 및 타겟 이미지는 모두 $[-1,1]$ 범위로 정규화하였다. Generator 출력에는 네트워크의 안정적인 학습을 위해 Tanh 활성 함수를 적용해 동일한 범위를 유지하도록 했다. 학습이 끝난 후에는 출력 이미지를 $[0,255]$ 범위로 역정규화(denormalization) 하여 결과를 시각적으로 비교하고, PSNR, SSIM, LPIPS 같은 표준 지표를 계산하도록 했다.

이 정규화·역정규화 과정은 두 가지 측면에서 중요하다. 첫째, 정규화는 학습 과정에서 픽셀 값 분포의 편차를 줄여 학습 안정성을 높인다. 둘째, 역정규화는 결과 이미지를 직관적으로 확인하고 표준 지표를 계산할 수 있도록 한다. 따라서 본 연구의 학습 및 평가 과정은 정규화와 역정규화를 포함하는 전처리·후처리 과정 위에서 이루어졌다.

4. 실험 및 결과

4.1 데이터 및 노이즈 구성

본 연구에서는 DIV2K [5]와 BSDS500 [6] 데이터셋을 학습 및 평가에 활용했다. 모든 이미지는 256×256 해상도로 변환했으며, 깨끗한 clean ground truth 이미지에 화이트벨런스 불균일성 노이즈를 인위적으로 합성해 학습용 입력 이미지를 만들었다.

화이트벨런스 노이즈는 RGB 채널별 밝기에 서로 다른 편차를 주어 특정 색이 과도하게 강조되거나 억제되도록 구성했다. 이는 실제 촬영 환경에서 나타나는 조명 스펙트럼의 불균일성과 센서 반응 차이를 반영한다.

4.2 실험 설정

모든 실험은 Google Colab 환경에서 PyTorch로 진행했다. 학습은 batch size 8, 학습률 2×10^{-4} , Adam optimizer($\beta_1=0.5, \beta_2=0.999$) 조건에서 150 epoch 동안 수행했다.

Generator 출력에는 Tanh 함수를 적용해 정규화 범위를 유지했고, Discriminator는 PatchGAN 구조 [1]를 사용해 지역적 패치 단위에서 이미지의 진위를 판별하였다.

손실 함수는 L_GAN 손실, L1 손실, LPIPS 손실 [4]을 조합해 사용했으며, 초기 가중치는 $\lambda_{L1}=20$, $\lambda_{LPIPS}=1.0$ 으로 설정했다.

성능 평가는 LPIPS [4], PSNR, SSIM 세 가지 지표를 통해 진행했다. LPIPS는 시각적 유사도, PSNR은 화질 보존 정도, SSIM은 구조적 유사도를 측정하여 모델의 복원 성능을 다양한 측면에서 검증했다.

4.3 분해 실험

CBAM의 채널 어텐션 모듈(CAM)과 공간 어텐션 모듈(SAM)이 각각 어떤 역할을 하는지 확인하기 위해 분해 실험을 했다.

실험 #5(CAM only)는 CAM만 적용한 구조, 실험 #6(SAM only)는 SAM만 적용한 구조를 사용했으며, 두 실험 모두 동일한 학습 조건(150 epoch, batch size 8, Adam optimizer)에서 수행했다.

결과적으로 SAM만 적용했을 때는 성능 저하가 나타난 반면, CAM만 적용했을 때는 LPIPS, PSNR, SSIM 모든 지표에서 개선이 있었다. 즉, 채널별 특징 강조가 화이트벨런스 왜곡 복원에 효과적이라는 점을 보여준다. 결과적으로, SAM은 전역적인 색상 불균일성 처리에 약점을 보였지만 CAM은 화이트벨런스 복원에서 핵심적인 역할을 했음을 알 수 있다.

4.4 CAM 삽입 위치

CAM의 최적 삽입 위치를 검증하기 위해 Encoder 단계와 Decoder 단계에 각각 CAM을 배치한 실험을 진행했다. 실험 #7에서는 U-Net의 모든 Encoder 블록 출력 직후에 CAM을 삽입하였으며, 실험 #8에서는 모든 Decoder 블록 출력 직후에 CAM을 삽입하였다. 두 실험은 동일한 학습 조건에서 진행해 삽입 위치를 직접 비교할 수 있었다.

실험 결과, Decoder All 구조(#8)가 Encoder All 구조(#7)보다 LPIPS, PSNR, SSIM 모든 지표에서 우수한 성능을 보였다. 특히 LPIPS 지표에서 가장 크게 개선됨을 확인할 수 있었는데, 이는 디코더 단계에서 스킵 커넥션을 통합하고 최종 이미지를 복원하는 과정이 화이트벨런스 왜곡 복원의 핵심임을 보여준다. 반면, Encoder 단계에 CAM을 삽입한 경우 성능 향상은 제한적이었다.

4.5 손실 함수 가중치 최적화

앞선 실험으로 네트워크 구조는 CAM-Decoder All이 가장 적합함을 확인했다. 이어서 본 연구에서는 해당 구조를 기반으로 손실 함수의 가중치 조합을 달리하며 학습 성능에 미치는 영향을 검증하였다.

실험 #9에서는 LPIPS 손실의 가중치를 높여 시각적 유사도 보존 효과를 극대화했고, 실험 #10에서는 L1 손실의 가중치를 크게 설정해 픽셀 단위 정확도를 우선시했다. 실험 #11은 L1과 LPIPS 가중치를 동시에 강화해 두 지표가 균형 있게 향상되도록 했다.

실험 결과, 실험 #10이 가장 좋은 결과를 보였다. LPIPS는 0.0434로 가장 낮게 측정되었으며, PSNR 27.40, SSIM 0.8934를 기록해 전반적인 복원 성능에서 최적의 결과를 보였다. 실험 #11은 PSNR과 SSIM에서 더 높은 수치를 기록했지만, LPIPS 지표에서는 다소 성능 저하가 발생했다. 반면, 실험 #9는 LPIPS는 향상됐으나, PSNR과 SSIM에서는 충분한 성능을 내지 못했다.

이러한 결과는 화이트벨런스 불균일성 복원에서 L1 손실이 핵심적인 역할을 한다는 것을 알 수 있다. 즉, 화이트벨런스 왜곡 복원에서는 L1 손실의 비중이 핵심적이며, LPIPS는 보조적으로

활용하는 것이 가장 효과적임을 알 수 있었다.

4.6 종합 비교 및 최종 모델 성능

앞선 실험들을 종합한 결과, CAM 단독 사용과 Decoder All 구조가 네트워크 설계에서 가장 효과적이었고, 손실 함수 가중치에서는 L1 손실을 크게 반영한 실험 #10이 최적 성능을 달성했다.

표 1은 모든 실험에서의 최고 성능을 정리한 것이다. 제안 모델 #10은 기존 CBAM 구조에 비해 LPIPS는 0.0959에서 0.0434로 54.7% 감소했고, PSNR은 21.87에서 27.40으로 +5.53 dB 향상, SSIM은 0.7253에서 0.8934로 23.2% 개선됐다.

정성적 비교에서도, 제안 모델은 기존 구조보다 색상 왜곡을 효과적으로 보정했으며, 경계부 왜곡이나 채널 불균형 현상도 크게 줄어든 것을 확인할 수 있었다. 이는 제안 모델이 픽셀 단위 정확도와 시각적 유사도를 동시에 만족시켜, 실제 환경에서 발생할 수 있는 화이트밸런스 문제 해결에 유용한 복원 전략임을 보여준다.

표 1. 모든 실험에서의 최고 성능 요약

실험 번호	구성 (구조+손실)	LPIPS ↓	PSNR ↑	SSIM ↑	λ_1	ALPIPS
#4	Full CBAM, LPIPS $\times 1$ (Baseline , [1])	0.0959	21.87	0.7253	20	1.0
#8	CAM Dec All, LPIPS $\times 1$	0.0483	27.36	0.7743	20	1.0
#10	CAM Dec All, L1 $\times 5$	0.0434	27.40	0.8934	100	1.0
#11	CAM Dec All, L1 $\times 5$, LPIPS $\times 5$	0.0462	28.27	0.8907	100	5.0

5. 결론 및 향후 연구

이 연구에서는 화이트밸런스 불균일성 노이즈 제거를 위해 U-Net 기반 생성 네트워크에 채널 어텐션 모듈(CAM)을 적용하고, Decoder 전 구간 배치하는 구조적 최적화를 시도했다. 또한 손실 함수의 가중치를 조정하여 픽셀 단위 정확도(L1)와 시각적 유사도(LPIPS)를 동시에 고려할 수 있는 학습 전략을 설계했다.

실험 결과, 제안한 모델은 기존 CBAM 기반 구조 대비 LPIPS를 약 54.7% 낮추고 SSIM을 약 23.2% 높여, 시각적 품질과 구조 보존 측면 모두에서 뚜렷한 성능 향상을 보였다. 정성적 비교에서도 색상 왜곡과 채널 불균형 현상이 크게 줄어든 것을 확인할 수 있었다. 즉, CAM 기반의 Decoder All 구조와 L1 중심 손실 함수 조합이 화이트밸런스 왜곡 복원 문제에 특히 효과적임을 보여준다.

다만, 이번 연구는 특정 노이즈 유형(화이트밸런스 왜곡)에 초점을 맞췄기 때문에, 실제 환경에서 발생하는 다양한 복합 노이즈 상황에 대한 검증은 부족하다. 향후에는 보다 다양한 촬영

환경을 반영한 데이터셋을 구축하고, 저조도나 고노이즈 조건에서도 모델이 잘 동작하는지를 확인할 필요가 있다. 더 나아가 어텐션 모듈의 경량화와 네트워크 최적화를 통해 실시간 적용 가능한 복원 모델로 확장하는 것도 중요한 과제다. 이러한 연구 방향은 제안된 접근법이 실제 화이트밸런스 복원 문제 해결에 활용될 가능성을 더욱 높여줄 것으로 기대된다.

참고 문헌

- [1] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, "Image-to-Image Translation with Conditional Adversarial Networks," Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2017, pp. 5967-5976.
- [2] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," Proc. Int. Conf. Medical Image Computing and Computer-Assisted Intervention (MICCAI), 2015, pp. 234-241.
- [3] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, "CBAM: Convolutional Block Attention Module," Proc. Eur. Conf. Computer Vision (ECCV), 2018, pp. 3-19.
- [4] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The Unreasonable Effectiveness of Deep Features as a Perceptual Metric," Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2018, pp. 586-595.
- [5] E. Agustsson and R. Timofte, "NTIRE 2017 Challenge on Single Image Super-Resolution: Dataset and Study," Proc. IEEE Conf. Computer Vision and Pattern Recognition Workshops (CVPRW), 2017, pp. 1122-1131.
- [6] P. Arbelaez, M. Maire, C. Fowlkes, and J. Malik, "Contour Detection and Hierarchical Image Segmentation," IEEE Trans. Pattern Analysis and Machine Intelligence (TPAMI), vol. 33, no. 5, pp. 898-916, 2011.
- [7] A. Buchsbaum, "A spatial processor model for object colour perception," Journal of the Franklin Institute, vol. 310, no. 1, pp. 1-26, 1980.
- [8] E. H. Land and J. J. McCann, "Lightness and retinex theory," Journal of the Optical Society of America, vol. 61, no. 1, pp. 1-11, 1971.
- [9] Y. Cheng, D. Yanlin, S. Xu, et al., "Deep White-Balance Editing," Proc. IEEE Int. Conf. Computer Vision (ICCV), 2019.